
Redes Neurais e Deep Learning


INICIALIZAÇÃO

Zenilton K. G. Patrocínio Jr zenilton@pucminas.br

Pré-Processamento de Dados – Básico



Pré-Processamento de Dados – Avançado



Pré-Processamento de Imagens

Apenas centrar os dados em zero


p.ex. considere o dataset CIFAR-10 com imagens [32,32,3]

- Subtrair a imagem média (p.ex. AlexNet)
 imagem média = vetor de dimensões [32,32,3]
- Subtrair a média por canal (p.ex. VGGNet)
 média ao longo de cada canal = 3 números

Não é comum normaliza nem decorrelacionar os pixels de uma imagem

Inicialização de Pesos

 Pergunta: que ocorre quando os pesos são inicializados com zero, isto é, W = 0?



Inicialização de Pesos

- Uma primeira idea: **Usar números randômicos pequenos**Usar uma distribuição normal com média zero e desvio padrão 10⁻²


$$W = 0.01* np.random.randn(D,H)$$


Funciona bem para redes pequenas, mas pode levar a distribuições não homogêneas de ativações ao longo das camadas de uma rede

Exemplo:

- Rede de 10 camadas
- 500 neurônios por camada
- Ativação Tanh
- Pesos inicializados com números randômicos pequenos

```
# assume some unit gaussian 10-D input data
D = np.random.randn(1000, 500)
hidden layer sizes = [500]*10
nonlinearities = ['tanh']*len(hidden layer sizes)
act = {'relu':lambda x:np.maximum(0,x), 'tanh':lambda x:np.tanh(x)}
Hs = \{\}
for i in xrange(len(hidden layer sizes)):
   X = D if i == 0 else Hs[i-1] # input at this layer
    fan in = X.shape[1]
    fan out = hidden layer sizes[i]
    W = np.random.randn(fan in, fan out) * 0.01 # layer initialization
    H = np.dot(X, W) # matrix multiply
   H = act[nonlinearities[i]](H) # nonlinearity
    Hs[i] = H # cache result on this layer
# look at distributions at each layer
print 'input layer had mean %f and std %f' % (np.mean(D), np.std(D))
layer means = [np.mean(H) for i,H in Hs.iteritems()]
layer stds = [np.std(H) for i,H in Hs.iteritems()]
for i,H in Hs.iteritems():
    print 'hidden layer %d had mean %f and std %f' % (i+1, layer means[i], layer stds[i])
# plot the means and standard deviations
plt.figure()
plt.subplot(121)
plt.plot(Hs.keys(), layer means, 'ob-')
plt.title('layer mean')
plt.subplot(122)
plt.plot(Hs.keys(), layer stds, 'or-')
plt.title('layer std')
# plot the raw distributions
plt.figure()
for i,H in Hs.iteritems():
    plt.subplot(1,len(Hs),i+1)
    plt.hist(H.ravel(), 30, range=(-1,1))
```






Todas as ativações se tornam zero!

P: pense sobre o passo retrógrado. Como são os gradientes?

Dica: lembre que a função de ativação é aplicada após o produto interno Wx




W = np.random.randn(fan in, fan out) * 1.0 # layer initialization

*1.0 ao invés de *0.01

Quase todos os neurônios ficaram completamente saturados em -1 ou +1


Gradientes serão todos nulos !!!



"Inicialização de Xavier" [Glorot et al., 2010]

Resultados razoáveis

 Derivação matemática supondo ativação linear





"Inicialização de Xavier" [Glorot et al., 2010]


Resultados razoáveis

Derivação matemática supondo ativação linear

Mas ao usar ReLU, não funciona: (







Inicialização de Pesos

Initialization adequada foi uma área ativa de pesquisa...

- Understanding the difficulty of training deep feedforward neural networks by Glorot and Bengio, 2010
- Exact solutions to the nonlinear dynamics of learning in deep linear neural networks by Saxe et al, 2013
- Random walk initialization for training very deep feedforward networks by Sussillo and Abbott, 2014
- Delving deep into rectifiers: Surpassing human-level performance on ImageNet classification by He et al., 2015
- Data-dependent Initializations of Convolutional Neural Networks by Krähenbühl et al., 2015
- All you need is a good init, Mishkin and Matas, 2015

•