ATUALIZAÇÃO DE PESOS

RMSPROP / ADAGRAD

Zenilton K. G. Patrocínio Jr
zenilton@pucminas.br

RMSProp

[Hinton et al., 2012]

Os gradientes podem variar muito, embora os parâmetros geralmente tenham a mesma escala

RMSProp

[Hinton et al., 2012]

Os gradientes podem variar muito, embora os parâmetros geralmente tenham a mesma escala

RMSProp (*Root Mean Squared Propagation*) ajusta os valores de gradientes pelo inverso de uma média móvel

RMSProp

[Hinton et al., 2012]

Os gradientes podem variar muito, embora os parâmetros geralmente tenham a mesma escala

RMSProp (*Root Mean Squared Propagation*) ajusta os valores de gradientes pelo inverso de uma média móvel

Define-se

$$s^{(t+1)} = \beta s^{(t)} + (1-\beta)\left(g^{(t)}\right)^2$$

em que:

- $s^{(t)}$ é o gradiente quadrático médio (média móvel) no passo t,

RMSProp

[Hinton et al., 2012]

Os gradientes podem variar muito, embora os parâmetros geralmente tenham a mesma escala

RMSProp (*Root Mean Squared Propagation*) ajusta os valores de gradientes pelo inverso de uma média móvel

Define-se

$$s^{(t+1)} = \beta s^{(t)} + (1-\beta)\left(g^{(t)}\right)^2$$

em que:

- $s^{(t)}$ é o gradiente quadrático médio (média móvel) no passo t,
- $\beta \in [0,1]$ é o fator de decaimento da média móvel,

RMSProp

[Hinton et al., 2012]

Os gradientes podem variar muito, embora os parâmetros geralmente tenham a mesma escala

RMSProp (*Root Mean Squared Propagation*) ajusta os valores de gradientes pelo inverso de uma média móvel

Define-se

$$s^{(t+1)} = \beta s^{(t)} + (1-\beta)\left(g^{(t)}\right)^2$$

quadrado elemento a elemento de $g^{(t)}$,
assim $s^{(t)}$ possui as mesmas dimensões que $g^{(t)}$

em que:

- $s^{(t)}$ é o gradiente quadrático médio (média móvel) no passo t,
- $\beta \in [0,1]$ é o fator de decaimento da média móvel,
- $g^{(t)}$ é o gradiente do *minibatch* no passo t

RMSProp

[Hinton et al., 2012]

Os gradientes podem variar muito, embora os parâmetros geralmente tenham a mesma escala

RMSProp (*Root Mean Squared Propagation*) ajusta os valores de gradientes pelo inverso de uma média móvel

Define-se

$$s^{(t+1)} = \beta s^{(t)} + (1-\beta)\left(g^{(t)}\right)^2$$

quadrado elemento a elemento de $g^{(t)}$,
assim $s^{(t)}$ possui as mesmas dimensões que $g^{(t)}$

em que:

- $s^{(t)}$ é o gradiente quadrático médio (média móvel) no passo t,
- $\beta \in [0,1]$ é o fator de decaimento da média móvel,
- $g^{(t)}$ é o gradiente do *minibatch* no passo t

A regra de atualização do **RMSProp** é dada por:

$$W^{(t+1)} = W^{(t)} - \alpha \frac{g^{(t)}}{\sqrt{s^{(t)}}}$$

→ divisão elemento a elemento!

ADAGRAD

[Duchi et al., 2011]

ADAGRAD (*ADAptive GRADient*) é semelhante ao RMSProp, porém utiliza a ***soma acumulada*** dos quadrados dos gradientes

ADAGRAD

[Duchi et al., 2011]

ADAGRAD (*ADAptive GRADient*) é semelhante ao RMSProp, porém utiliza a ***soma acumulada*** dos quadrados dos gradientes

Define-se

$$c^{(t)} = \sum_{j=1}^{t} \left(g^{(j)}\right)^2$$

quadrado elemento a elemento de $g^{(t)}$,
assim $c^{(t)}$ possui as mesmas dimensões que $g^{(t)}$

ADAGRAD

[Duchi et al., 2011]

ADAGRAD (*ADAptive GRADient*) é semelhante ao RMSProp, porém utiliza a ***soma acumulada*** dos quadrados dos gradientes

Define-se

$$c^{(t)} = \sum_{j=1}^{t} \left(g^{(j)}\right)^2$$

quadrado elemento a elemento de $g^{(t)}$,
assim $c^{(t)}$ possui as mesmas dimensões que $g^{(t)}$

Assim, $c^{(t)}$ representa o gradiente quadrático ***acumulado*** no passo t

ADAGRAD

[Duchi et al., 2011]

ADAGRAD (*ADAptive GRADient*) é semelhante ao RMSProp, porém utiliza a ***soma acumulada*** dos quadrados dos gradientes

Define-se

$$c^{(t)} = \sum_{j=1}^{t} \left(g^{(j)}\right)^2$$

quadrado elemento a elemento de $g^{(t)}$,
assim $c^{(t)}$ possui as mesmas dimensões que $g^{(t)}$

Assim, $c^{(t)}$ representa o gradiente quadrático ***acumulado*** no passo t

A regra de atualização do **ADAGRAD** é dada por:

$$W^{(t+1)} = W^{(t)} - \alpha \frac{g^{(t)}}{\sqrt{c^{(t)}}}$$

$\rightarrow$ divisão elemento a elemento!

OBS: $c^{(t)}$ tende a crescer linearmente em função de t, assim o ADAGRAD reduz sua taxa de aprendizado efetiva ao longo do tempo em $1/\sqrt{t}$

RMSprop × ADAGRAD

```
# RMSProp
cache = decay_rate * cache + (1 - decay_rate) * dx**2
x += - learning_rate * dx / (np.sqrt(cache) + 1e-7)
```

```
# Adagrad update
cache += dx**2
x += - learning_rate * dx / (np.sqrt(cache) + 1e-7)
```

RMSprop × ADAGRAD

```
# RMSProp
cache = decay_rate * cache + (1 - decay_rate) * dx**2
x += - learning_rate * dx / (np.sqrt(cache) + 1e-7)
```

```
# Adagrad update
cache += dx**2
x += - learning_rate * dx / (np.sqrt(cache) + 1e-7)
```

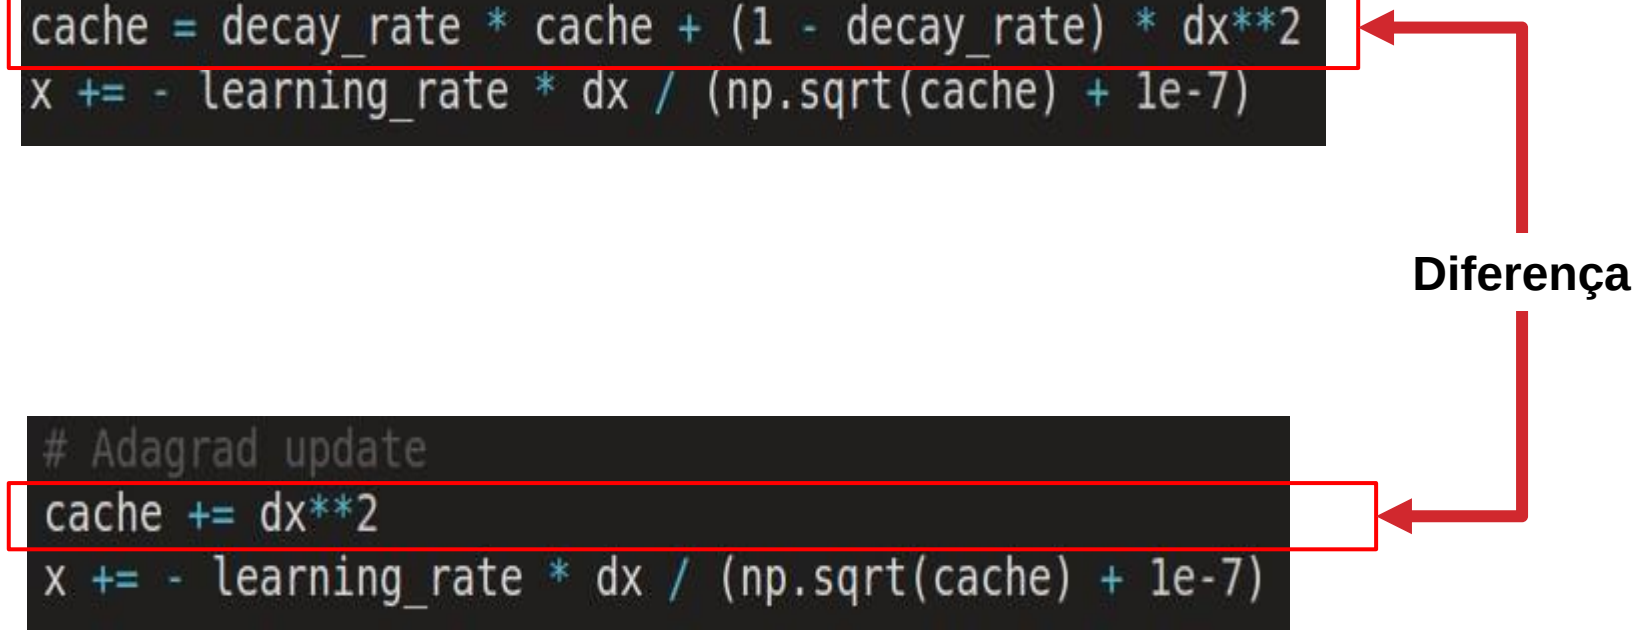

RMSProp × ADAGRAD

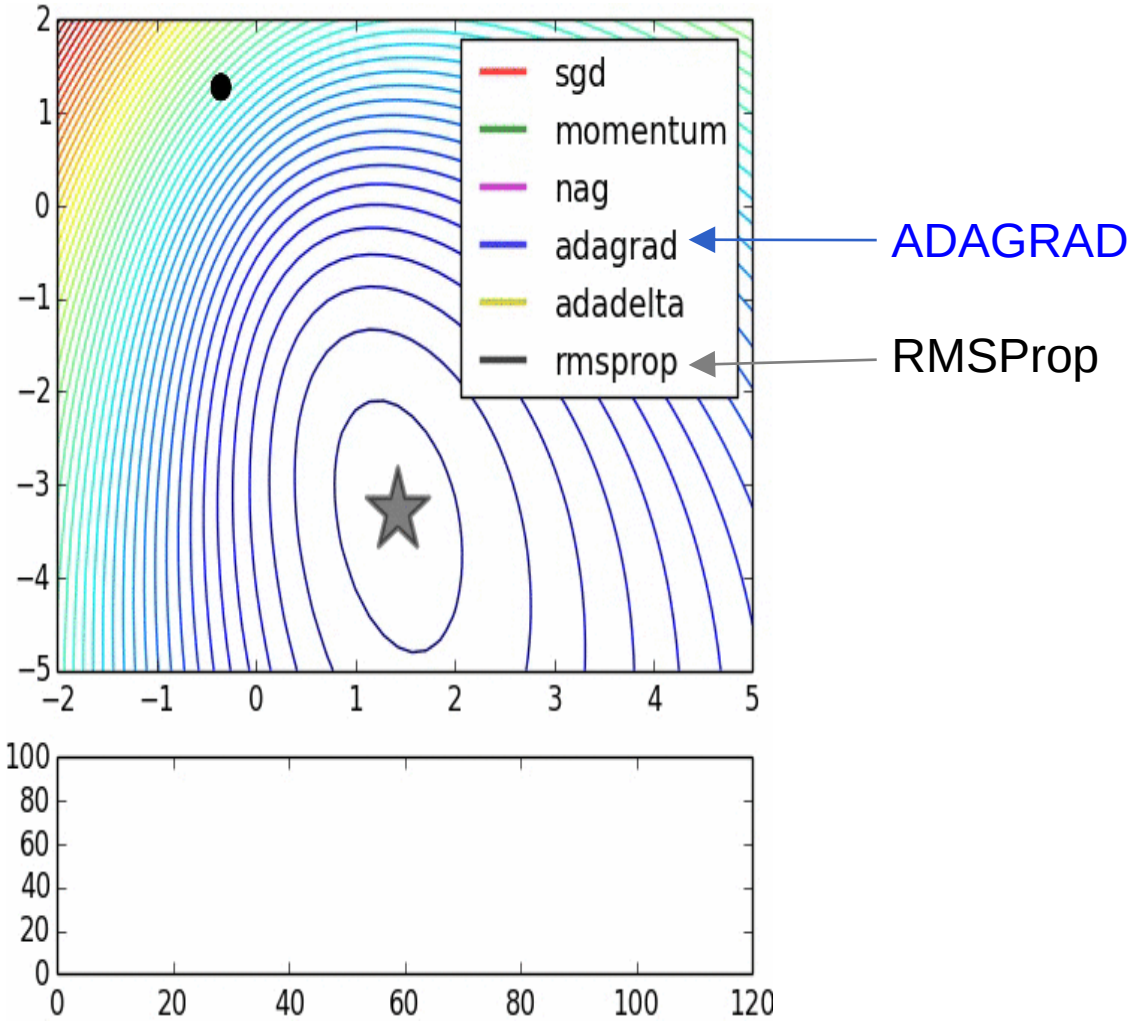

Crédito: Alec Radford, 2015

RMSProp × ADAGRAD

- Como ambos normalizam magnitudes de gradiente, o RMSProp e o ADAGRAD funcionam muito bem em conjuntos de dados com grande variação na magnitude de gradientes

RMSProp × ADAGRAD

- Como ambos normalizam magnitudes de gradiente, o RMSProp e o ADAGRAD funcionam muito bem em conjuntos de dados com grande variação na magnitude de gradientes

- O exemplo mais comum de aplicação são dados textuais, nos quais os gradientes variam de 4 a 5 ordens de magnitude

RMSProp × ADAGRAD

- Como ambos normalizam magnitudes de gradiente, o RMSProp e o ADAGRAD funcionam muito bem em conjuntos de dados com grande variação na magnitude de gradientes

- O exemplo mais comum de aplicação são dados textuais, nos quais os gradientes variam de 4 a 5 ordens de magnitude

- O uso do RMSProp / ADAGRAD pode acelerar o aprendizado de modelos de texto em 2-3 ordens de magnitude

RMSProp × ADAGRAD

- Como ambos normalizam magnitudes de gradiente, o RMSProp e o ADAGRAD funcionam muito bem em conjuntos de dados com grande variação na magnitude de gradientes

- O exemplo mais comum de aplicação são dados textuais, nos quais os gradientes variam de 4 a 5 ordens de magnitude

- O uso do RMSProp / ADAGRAD pode acelerar o aprendizado de modelos de texto em 2-3 ordens de magnitude

- Porém, menos eficaz quando existem fortes dependências entre as características

RMSProp × ADAGRAD

- O RMSProp é uma abordagem heurística, enquanto o ADAGRAD possui limites formais na sua taxa de convergência, embora apenas para problemas convexos

RMSProp × ADAGRAD

- O RMSProp é uma abordagem heurística, enquanto o ADAGRAD possui limites formais na sua taxa de convergência, embora apenas para problemas convexos

- A taxa de aprendizado no RMSProp é fixa ao longo do tempo, sendo mais adequado para tarefas de treinamento de longa duração

RMSProp × ADAGRAD

- O RMSProp é uma abordagem heurística, enquanto o ADAGRAD possui limites formais na sua taxa de convergência, embora apenas para problemas convexos

- A taxa de aprendizado no RMSProp é fixa ao longo do tempo, sendo mais adequado para tarefas de treinamento de longa duração

- A magnitude da soma dos gradientes quadráticos do ADAGRAD cresce linearmente com o tempo t; portanto, a taxa de aprendizado no ADAGRAD reduz em $1/\sqrt{t}$, o que é bastante agressivo (podendo ser bom para modelos curtos e fáceis de treinar, porém rápido demais para treinos de longa duração)

RMSProp × ADAGRAD

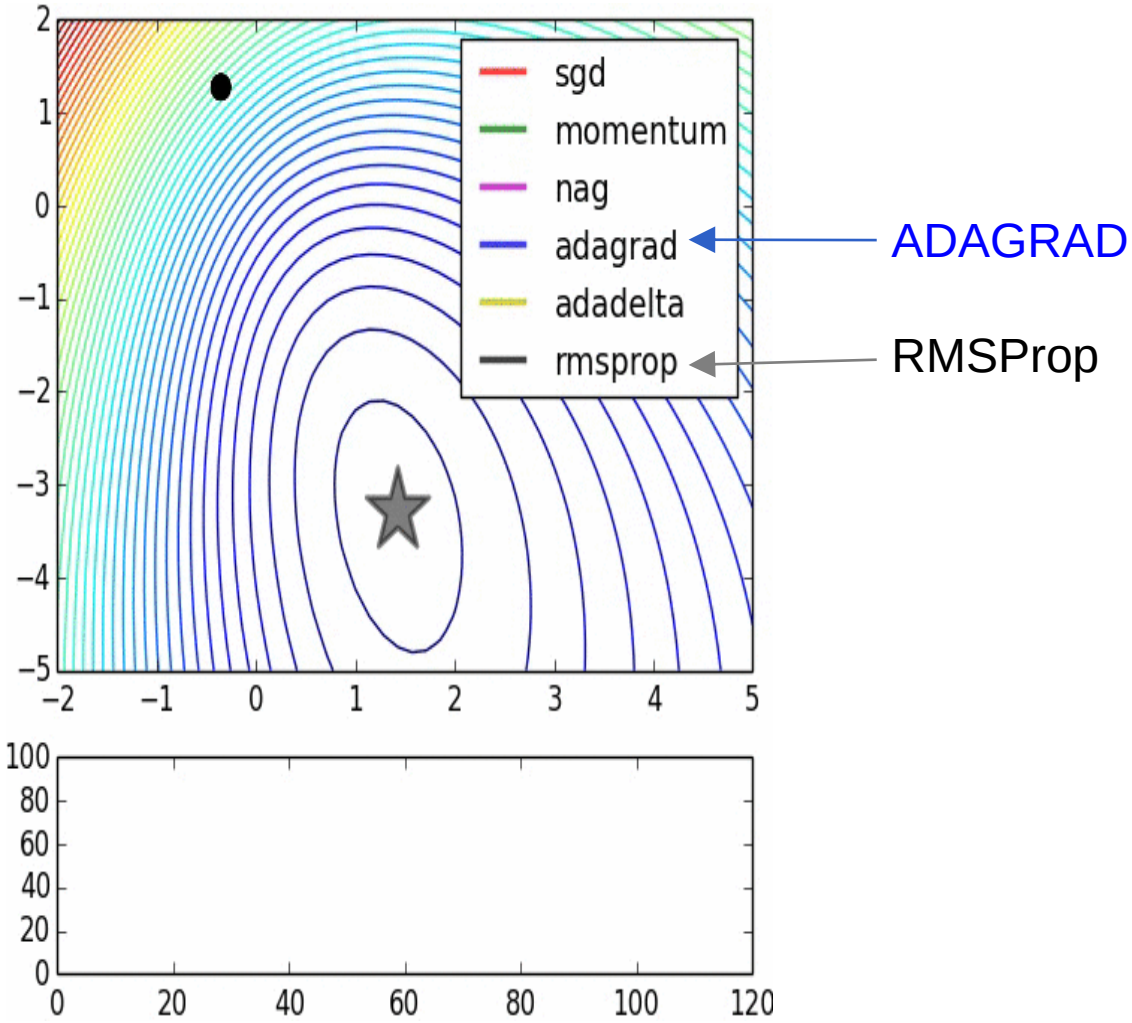

Crédito: Alec Radford, 2015